

Лабораторна робота №3. Агент з інструментами, станом і human-in-the-loop

25 серпня 2026 р.

Мета

Реалізувати агента з типізованими інструментами, явним циклом і бюджетом кроків, перетворити його на граф станів із checkpoint і додати підтвердження людини на незворотній дії.

Робота спирається на лекції 11, 12, 14, 15. Аудиторний час — 4 години, самостійна робота — 8 годин.

Теоретичні відомості

Агент відрізняється від воркфлоу не потужністю моделі, а тим, хто вирішує наступний крок: у воркфлоу маршрут намальований людиною, в агенті модель сама обирає послідовність дій. Ціна цієї свободи — необхідність зовнішніх обмежень, бо модель не має власного уявлення про бюджет, права й зупинку.

- **Інструмент є типізованим контрактом.** Оголошення складається з імені, опису для моделі, схеми аргументів, переліку обов'язкових полів, перелічуваних значень і схеми результату. Схема каже *як* викликати, опис каже *коли*: саме за описом модель обирає між схожими інструментами, і два майже однакові описи дають нестабільний вибір від запуску до запуску.
- **Помилка інструмента є вхідними даними для моделі, а не аварією.** Специфікація MCP розділяє протокольні помилки, корисні застосунку, і помилки виконання, які віддають моделі як зворотний зв'язок, придатний до дії. Стек-трейс у контексті забирає крок і не дає нічого; повідомлення «поле **date**: очікується формат RPPP-MM-DD» повертає агента на маршрут. Окремо від збою стоїть порожній результат: це успішний виклик, і поводитися з ним треба інакше.

- **Цикл без явного критерію зупинки** — це нескінченний цикл із чужим бюджетом. Тому задаються ліміт кроків, ліміт часу і перелік дозволених дій, а вичерпання бюджету не мовчить: агент віддає зібране, позначає задачу незавершеною і передає людині. Прохання «зроби не більше восьми кроків» у промпті обмеженням не є.
- **Неявний цикл важко відновити й перевірити, тому його роблять графом:** вузли — детерміновані або модельні кроки, ребра — переходи, стан — типізована структура, що передається між вузлами. Checkpointer зберігає знімок стану після кожного супер-кроку, тому падіння процесу не відкидає маршрут на початок: відновлення продовжує з останнього знімка і повторно виконує лише вузол, перерваний посередині.
- **Гарантія відновлення** — *at-least-once*, а не *exactly-once*, і залежить вона від режиму запису: за відкладеного запису (*durability="async"*) можна втратити й останній завершений крок, тому для відтворюваної демонстрації задають *durability="sync"*. Захистом від подвоєння побічного ефекту є ключ ідемпотентності, обчислений до виклику, а не сподівання, що повтору не станеться.
- **Людина в циклі** — елемент архітектури, а не кнопка в інтерфейсі. Підтвердження, редагування стану і вибір гілки є трьома різними механізмами, і гарантією виступає топологія графа: незворотна дія стоїть *після* точки зупинки.

Корисні посилання для ознайомлення:

- Yao S. та ін. [ReAct: Synergizing Reasoning and Acting in Language Models](#), ICLR 2023;
- Anthropic, [Building Effective Agents](#);
- Anthropic, [Writing tools for agents](#);
- LangGraph: [Persistence](#) та [Human-in-the-loop](#);
- Model Context Protocol, [Server: Tools](#).

Порядок виконання

Позначка *ауд.* означає, що крок виконується на занятті, *сам.* — самостійно. Аудиторна частина розрахована на 4 години.

1. **Реалізувати три інструменти** (50 хв, ауд.) з JSON-схемами аргументів і результату: калькулятор, читання з локальної бази SQLite лише для читання і пошук-заглушка з фіксованим набором відповідей. Для кожного заповнити всі шість полів контракту.

2. **Реалізувати цикл ReAct вручну** (60 хв, ауд.), без агентного фреймворку: думка, дія, спостереження, з логуванням кожного кроку і підрахунком токенів службового обміну.
3. **Задати бюджети** (30 хв, ауд.): не більше 8 викликів інструментів і 60 секунд на задачу — *у коді циклу, не в промпті*.
Перевірка: у логах є щонайменше один вичерпаний бюджет із коректним завершенням, а не з винятком.
4. **Реалізувати типізовані помилки** (40 хв, ауд.) для шести класів: невалідний аргумент, не знайдено, немає прав, ліміт швидкості, збій сервісу, порожній результат.
Перевірка: з тексту помилки впливає наступна дія агента; стек-трейс у контекст не потрапляє. У логах видно щонайменше одне успішне самовиправлення моделі.
5. **Перенести цикл у граф станів** (50 хв, ауд.) — **LangGraph** або власна реалізація — з не менш ніж п'ятьма вузлами і двома умовними переходами. Стан описати типізованою структурою.
Перевірка: лічильник кроків живе *ключем стану*, інакше він не переживе відновлення.
6. **Додати checkpoint** (40 хв, сам.) зі збереженням у SQLite і режимом `durability="sync"`. Перервати процес сигналом `kill -9` усередині чистого (без побічних ефектів) вузла і продовжити з останнього checkpoint.
Перевірка: раніше завершені вузли не виконуються повторно, перерваний виконується наново. У звіті вказати, які кроки повторились і чому це не помилка.
7. **Додати незворотну дію і людину в контурі** (50 хв, сам.): четвертий інструмент, що змінює стан (наприклад, створення запису), і переривання з підтвердженням перед ним. Заборона має діяти на рівні графа, а не тексту промпта.
Найважливіша перевірка роботи: побічний ефект стоїть *після* точки зупинки. Якщо перед — після відновлення запис створиться двічі.
8. **Перевірити ідемпотентність** (30 хв, сам.): підтверджений запис, повторений після відновлення з checkpoint, не створює другого. Протокол відновлення дає at-least-once, тому захистом є ключ ідемпотентності, обчислений до виклику.
9. **Прогнати набір задач** (50 хв, сам.): 20 задач, з яких не менше п'яти потребують двох і більше інструментів, а дві — свідомо нерозв'язні. Звести в таблицю: частку розв'язаних, середню кількість кроків, кількість вичерпаних бюджетів, кількість відпрацьованих типізованих помилок.

Перевірка: на нерозв'язних агент зупиняється за бюджетом, а не циклиться.

10. **Здати роботу:** код і README, схему графа, лог 20 прогонів, демонстрацію відновлення після падіння, демонстрацію підтвердження людини і висновок до 200 слів про те, які кроки варто було винести з моделі в детермінований код.

Крок 7 варто спробувати спершу *неправильно* — поставити запис до переривання і побачити подвійний ефект власними очима. Це найкраще запам'ятовується.

Контрольні запитання

1. За якою ознакою задачу віддають агенту, а не workflow?
2. Чому опис інструмента вважають частиною промпта?
3. Що саме повертає модель, коли «викликає інструмент»?
4. Чим думка в ReAct відрізняється від дії з погляду оновлення контексту?
5. Чому порожній результат виділяють окремо від збою сервісу?
6. Що має статися при вичерпанні бюджету кроків і чого статися не має?
7. Які переваги дає граф станів, яких не дає цикл `while`?
8. Після відновлення з checkpoint запис створився двічі. Де помилка?
9. Чому підтвердження людини реалізують у графі, а не інструкцією в промпті?
10. Агент повторює той самий пошук п'ять разів поспіль. Які три причини найімовірніші?

Література

1. Shinn N. та ін. [Reflexion: Language Agents with Verbal Reinforcement Learning](#). NeurIPS, 2023.
2. Cemri M. та ін. [Why Do Multi-Agent LLM Systems Fail?](#) arXiv:2503.13657, 2025.
3. OWASP GenAI Security Project. [LLM06: Excessive Agency](#), 2025.